

PHÁT HIỆN WATERMARK TRONG ẢNH SỐ

Môn: Thị giác Máy tính

Lê Anh Đức - 23120236

Đặng Nguyễn Thái Đạt - 23120227

Mục lục

- 1 Tóm tắt
- 2 Giới thiệu
 - Bối cảnh và Vấn đề nghiên cứu
 - Ý nghĩa thực tiễn
 - Đóng góp
- 3 Mô hình đề xuất
 - Kiến trúc tổng quát
 - Tiền xử lý (Preprocessing)
 - Trích xuất đặc trưng (Feature Extraction)
 - Channel Attention (SE-Net)
 - Phân loại (Classification)
 - Hàm mất mát (Loss Function)
 - Tối ưu hóa (Optimizer)
 - Data Augmentation
 - Cải tiến nâng cao
- 4 Thực nghiệm và kết quả

Tóm tắt

Nghiên cứu này đề xuất một mô hình lai (hybrid) kết hợp mạng nơ-ron tích chập (CNN) với phân tích miền tần số để phát hiện watermark trong ảnh số.

Bài toán phát hiện watermark đóng vai trò quan trọng trong việc bảo vệ bản quyền và xác thực nguồn gốc nội dung số. Mô hình đề xuất sử dụng kiến trúc hai nhánh:

- Nhánh RGB: sử dụng ResNet18 để trích xuất đặc trưng không gian
- Nhánh tần số: sử dụng FFT để nắm bắt các thay đổi vi mô trong miền tần số

Bối cảnh

Trong kỷ nguyên số và sự bùng nổ của nội dung tạo bởi AI (AIGC), việc bảo vệ bản quyền và xác thực nguồn gốc hình ảnh trở nên cấp thiết do tình trạng sao chép và chỉnh sửa dễ dàng. Watermark gồm hai loại: nhìn thấy được (visible) và ẩn (invisible).

Vấn đề nghiên cứu

Bài toán phát hiện watermark trong ảnh số đối mặt với nhiều thách thức:

- **Watermark nhìn thấy (visible):** Dễ phát hiện bằng mắt thường, nhưng việc xác định vị trí chính xác và phân biệt với các đối tượng tương tự vẫn là bài toán khó.
- **Watermark ẩn (invisible):** Phụ thuộc nhiều vào thuật toán nhúng cụ thể, rất khó phát hiện đối với watermark "unknown".
- **Watermark yếu:** Các tác động như nén JPEG, resize, blur làm giảm tín hiệu watermark đáng kể, gây khó khăn cho việc phát hiện.
- **Tổng hợp:** Cần mô hình có khả năng phát hiện cả hai loại watermark với độ chính xác cao trong nhiều điều kiện môi trường khác nhau.

Ý nghĩa thực tiễn

- Hỗ trợ kiểm tra bản quyền hình ảnh tự động trên các nền tảng số
- Phát hiện ảnh bị đánh cắp hoặc sử dụng trái phép
- Xác định nguồn gốc ảnh trong điều tra số
- Ứng dụng trong an ninh mạng và truyền thông

Đóng góp

Nghiên cứu đề xuất một mô hình hybrid kết hợp CNN với phân tích miền tần số để giải quyết bài toán phát hiện watermark. Các đóng góp chính bao gồm:

- 1 Kiến trúc hai nhánh kết hợp đặc trưng không gian (spatial) từ ResNet18 và đặc trưng tần số (frequency) từ FFT.
- 2 Áp dụng cơ chế SE-Net attention để tăng cường khả năng trích xuất đặc trưng.
- 3 Xây dựng pipeline huấn luyện với các kỹ thuật augmentation đa dạng.
- 4 Thực nghiệm và đánh giá trên các tập dữ liệu chuẩn.

Kiến trúc tổng quát

Chúng tôi đề xuất mô hình Hybrid CNN-Frequency với kiến trúc hai nhánh (dual-branch).

Mô hình bao gồm các thành phần chính:

- Preprocessing: Tiền xử lý ảnh đầu vào với hai nhánh (RGB và FFT)
- Feature Extraction: Trích xuất đặc trưng từ cả hai nhánh
- Fusion & Attention: Kết hợp đặc trưng và áp dụng attention
- Classification: Phân loại nhị phân

Tiền xử lý - Nhánh RGB

- Resize: 224×224
- Normalization: Sử dụng ImageNet mean và std
 - Mean: [0.485, 0.456, 0.406]
 - Std: [0.229, 0.224, 0.225]

Tiền xử lý - Nhánh tần số

Ảnh đầu vào được chuyển đổi sang miền tần số sử dụng FFT:

$$F_{freq} = \log(|\text{FFT}(I)| + 1)$$

Trong đó:

- $\text{FFT}(I)$: Fast Fourier Transform của ảnh đầu vào
- $|\cdot|$: Lấy magnitude
- $\log$: Log transformation để compress dynamic range

Tiền xử lý - Nhánh tần số

Quy trình tạo frequency representation:

- ➊ Chuyển ảnh sang grayscale
- ➋ Áp dụng FFT 2D
- ➌ Shift để đưa DC component ra giữa
- ➍ Lấy magnitude spectrum
- ➎ Log transform: $\log(\text{magnitude} + 1)$
- ➏ Normalize về $[0, 1]$
- ➐ Resize về 224×224

Trích xuất đặc trưng - RGB Backbone

Sử dụng ResNet18 pretrained trên ImageNet làm backbone cho nhánh RGB. ResNet18 có 11.7M parameters, cung cấp sự cân bằng tốt giữa performance và efficiency.

Trích xuất đặc trưng - Frequency Branch

Nhánh tần số sử dụng 1D CNN với 3 layers để trích xuất đặc trưng từ frequency representation:

Layer	Kernel Size	Channels	Output
Conv1d ₁	3	32	224×32
Conv1d ₂	3	64	112×64
Conv1d ₃	3	128	56×128
GlobalAvgPool			128

Output: 128-dimensional feature vector

Trích xuất đặc trưng - Fusion

Hai nhánh được kết hợp thông qua concatenation:

$$F_{fused} = \text{Concat}(F_{RGB}, F_{freq})$$

$$F_{fused} \in \mathbb{R}^{640}(512 + 128)$$

Sau đó, một FC layer giảm chiều: FC(640 $\rightarrow$ 512)

Channel Attention

Áp dụng Squeeze-and-Excitation (SE) attention để tăng cường đặc trưng:

Bước 1 - Squeeze (Global Average Pooling):

$$z = F_{sq}(u) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_{ij}$$

Bước 2 - Excitation:

$$s = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot z))$$

Bước 3 - Scale:

$$v = F_{scale}(u, s) = s \cdot u$$

Trong đó:

- $W_1 \in \mathbb{R}^{C/r \times C}$ ($r = 16$ là reduction ratio)
- $W_2 \in \mathbb{R}^{C \times C/r}$
- σ : Sigmoid activation

Phân loại

Lớp classification bao gồm:

Layer	Configuration
FC1	512 $\rightarrow$ 256, ReLU
Dropout	0.5
FC2	256 $\rightarrow$ 2 (Binary classification)
Output	Softmax

Hàm mất mát

Sử dụng Cross-entropy loss:

$$\mathcal{L}_{CE} = - \sum_{i=1}^K y_i \log(\hat{y}_i)$$

Trong đó:

- y_i : ground truth label
- $\hat{y}_i$: predicted probability
- $K = 2$ (binary classification)

Tối ưu hóa

- **Optimizer:** AdamW
- **Learning rate:** 1e-4
- **Weight decay:** 1e-2
- **Scheduler:** Cosine annealing

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min}) \left(1 + \cos \frac{t\pi}{T_{max}} \right)$$

Trong đó η_t là learning rate tại step t , T_{max} là tổng số epochs.

Data Augmentation

Để tăng cường khả năng tổng quát hóa, chúng tôi áp dụng các kỹ thuật augmentation:

Kỹ thuật	Tham số	Xác suất
Random Horizontal Flip		0.5
Random Rotation	$\pm 15^\circ$	0.5
Color Jitter	brightness=0.2, contrast=0.2	0.3
JPEG Compression	quality=70-90	0.3
Gaussian Noise	$\sigma = 5$	0.2

Cải tiến nâng cao

① Multi-scale Input

Sử dụng ảnh đầu vào ở hai scales: 224 và 448, ensemble predictions.

② Test-Time Augmentation (TTA)

Áp dụng horizontal flip và rotation nhẹ khi inference, average predictions.

③ Semi-supervised Learning

Sử dụng pseudo-labeling để mở rộng tập training.

Dataset

Dataset	Nguồn	Số lượng	Loại WM
CLWD	arXiv 2012.076163	70,000	Visible
COCO val+synthetic	COCO 2017	5,000	Invisible

Chia train/val/test

- Training: 70%
- Validation: 15%
- Testing: 15%

Metric đánh giá

Metric	Công thức	Ý nghĩa
Accuracy	$(TP+TN)/Total$	Độ chính xác tổng
Precision	$TP/(TP+FP)$	Độ chính xác dự đoán
Recall	$TP/(TP+FN)$	Độ nhạy
F1-score	$2PR/(P+R)$	Cân bằng P/R
Inference time	ms/ảnh	Tốc độ

Kết quả

Metric	Baseline 1 (ResNet18)	Baseline 2 (MobileNet)	Ours v1	Ours v2
Accuracy	84.15%	78.06%	85.12%	84.99%
Precision	87.62%	91.08%	93.64%	89.29%
Recall	80.76%	63.83%	76.42%	80.66%
F1-score	84.05%	75.06%	84.16%	84.76%
Inference time	4.9ms	7.8ms	6.1ms	7.3ms

Ours v1 đạt accuracy cao nhất (85.12%) với precision 93.64%.

Ours v2 cân bằng hơn với F1-score 84.76% và recall 80.66%.